

## Introdução à Estatística

A estatística é um conjunto de técnicas que permite, de forma sistemática, organizar, descrever, analisar e interpretar dados oriundos de estudos ou experimentos, realizados em qualquer área do conhecimento.

A estatística é composta pelas seguintes áreas:

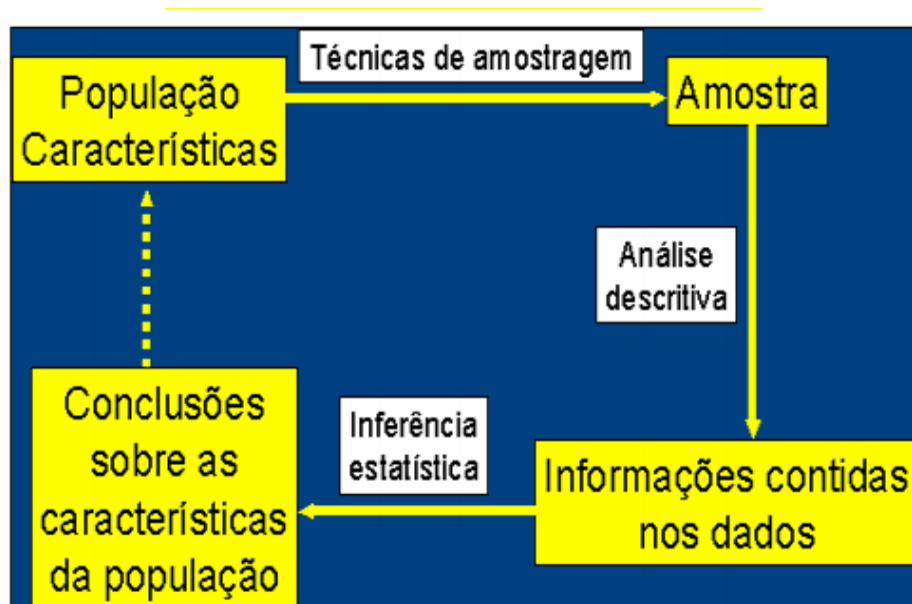
- Estatística Descritiva
- Probabilidade
- Inferência Estatística

A **estatística descritiva** é a etapa inicial da análise utilizada para descrever e resumir os dados. A disponibilidade de uma grande quantidade de dados e de métodos computacionais muito eficientes revigorou esta área da estatística.

A **teoria de probabilidades** nos permite descrever os fenômenos aleatórios, ou seja, aqueles em que está presente a incerteza.

A **inferência estatística** é o estudo de técnicas que possibilitam a extrapolação, a um grande conjunto de dados, das informações e conclusões obtidas a partir da amostra.

### Etapas da Análise Estatística



### Amostragem


Uma área importante em muitas aplicações Estatísticas é a da Tecnologia de Amostragem.

Exemplos de Aplicação:


- Pesquisa de mercado,
- Pesquisa de opinião,
- Avaliação do processo de produção,
- Praticamente em todo experimento

**Amostragem Aleatória**

Cada elemento da população tem a mesma chance de ser escolhido.

**Amostragem Estratificada**

Classificar a população em, ao menos dois estratos e extrair uma amostra de cada um.

**Amostragem Sistemática**

Escolher cada elemento de ordem k.

**Amostragem por Conglomerados**

Dividir em seções a área populacional, selecionar aleatoriamente algumas dessas seções e tomar todos os elementos das mesmas.

**Amostragem de Conveniência**

Utilizar resultados de fácil acesso

**Estatística Descritiva**

O que se faz com as observações coletadas?

Resposta: 1ª etapa - resumo dos dados.

## Variável

Qualquer característica associada a uma população. É a característica que vai ser observada, medida ou contada nos elementos da população ou da amostra e que pode variar, ou seja, assumir um valor diferente de elemento para elemento.

Não basta identificar a variável a ser trabalhada, é necessário fazer-se distinção entre os tipos de variáveis:

Classificação de variáveis		
Qualitativa	Nominal	sexo, cor dos olhos
	Ordinal	classe social, grau de instrução
Quantitativa	Contínua	peso, altura, salário
	Discreta	número de filhos, número de carros

## Medidas Descritivas

Uma das maneiras de se resumir os dados de uma variável quantitativa, são usar o que chamamos de medidas descritivas que auxiliam a análise do comportamento dos dados. Tais dados são provenientes de uma população ou de uma amostra, o que exige uma notação específica para cada caso.

Classificam-se as medidas descritivas como: medidas posição (tendência central), medidas de dispersão, medidas de assimetria e de curtose.

## Medidas de Tendência Central

As medidas de tendência central são assim denominadas por indicarem um ponto em torno do qual se concentram os dados. A seguir, são definidas as principais medidas de tendência central: média, mediana e moda.

### Média aritmética ( $\mu$ ou $\bar{x}$ )

A média aritmética ( $\bar{X}$ ) é a soma de todos os valores observados da variável dividida pelo número total de observações. Sob uma visão geométrica a média de uma distribuição é o centro de gravidade, representa o ponto de equilíbrio de um conjunto de dados. É a medida de tendência central mais utilizada para representar a massa de dados.

Seja ( $x_1, \dots, x_n$ ) um conjunto de dados. A média é dada por:

$$\mu = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n} = \frac{\sum_{i=1}^n x_i}{n}$$

para dados populacionais ou amostrais, respectivamente.

Caso os dados estejam apresentados segundo uma distribuição de frequência, tem-se:

$$\mu = \frac{x_1 F_1 + x_2 F_2 + x_3 F_3 + \dots + x_n F_n}{n} = \frac{\sum_{i=1}^n x_i F_i}{n}$$

Observe que no caso de dados agrupados a média é obtida a partir de uma ponderação, onde os pesos são as frequências absolutas de cada classe e  $x_i$  é o ponto médio da classe  $i$ .

Citam-se a seguir, algumas propriedades da média aritmética:

1. a média é um valor calculado facilmente e depende de todas as observações
2. é única em um conjunto de dados e nem sempre tem existência real, ou seja, nem sempre é igual a um determinado valor observado
3. a média é afetada por valores extremos observados
4. por depender de todos os valores observados, qualquer modificação nos dados fará com que a média fique alterada. Isto quer dizer que somando-se, subtraindo-se, multiplicando-se ou dividindo-se uma constante a cada valor observado, a média ficará acrescida, diminuída, multiplicada ou dividida desse valor.
5. a soma da diferença de cada valor observado em relação à média é zero, ou seja, a soma dos desvios é zero.  $\sum (x_i - \bar{x}) = 0$

A propriedade 5, é de extrema importância para a definição de variância, uma medida de dispersão a ser definida posteriormente.

Destaca-se, ainda, que a propriedade 3, quando se observam no conjunto dados discrepantes, faz da média uma medida não apropriada para representar os dados. Neste caso, não existe uma regra prática para a escolha de uma outra medida.

Exemplo:

Para ilustrar, considere o número de filhos, por família, para um grupo de 8 famílias: 0, 1, 1, 2, 2, 2, 3, 4. Neste caso, a média é  $\mu = 1,875$  = filhos por família.

Entretanto, incluindo ao grupo uma nova família com 10 filhos, a média passa a ser  $\mu = 2,788$ , o que eleva em 48,16% o número médio de filhos por família.

Assim, ao observar a média, pode-se pensar que a maior parte das famílias deste grupo tem três filhos quando, na verdade, apenas uma tem três filhos.

### Moda ( $M_o$ )

A moda ( $M_o$ ) é o valor que apresenta a maior frequência da variável entre os valores observados. Para o caso de valores individuais, a moda pode ser determinada imediatamente observando-se o rol ou a frequência absoluta dos dados.

É relevante salientar que um conjunto de dados pode apresentar todos seus elementos com a mesma frequência absoluta, e neste caso não existirá um valor modal, o que significa que a distribuição será classificada como amodal.

Pode ocorrer, também, casos em que a sequência de observações apresente vários elementos com frequências iguais, implicando numa distribuição plurimodal.

O uso da moda é mais indicado quando se deseja obter, rapidamente, uma medida de tendência central. Um outro aspecto que favorece a utilização da moda é que seu valor não é afetado pelos valores extremos do conjunto de dados analisado.

Exemplo:

Seja um grupo de pessoas com idades de 2, 3, 1, 2 e 50 anos. Temos que  $M_o = 2$ .

A  $M_o = 2$  demonstra maior eficiência para caracterizar o grupo que a média aritmética.

### Mediana ( $M_e$ )

A mediana ( $M_e$ ) é o valor que ocupa a posição central da série de observações de uma variável, em rol, dividindo o conjunto em duas partes iguais, ou seja, a quantidade de valores inferiores à mediana é igual à quantidade de valores superiores a mesma.

Exemplo:

Retomando o exemplo do número de filhos por famílias, verifica-se que: para o caso de oito famílias, **n=8 (par)**, a mediana é determinada como a seguir:

x	$x_1$	$x_2$	$x_3$	$x_4$		$x_5$	$x_6$	$x_7$	$x_8$
Valor Esperado	0	1	1	2	$\frac{x_4 + x_5}{2}$	2	2	3	4
	4 observações				$M_e=2$	4 observações			

Quando se acrescenta ao grupo uma outra família com 10 filhos o tamanho da amostra passa a ser **n=9 (ímpar)**. Neste caso, a mediana é:

x	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$
Valor Esperado	0	1	1	2	2	2	3	4	10
	4 observações				$M_e=2$	4 observações			

Observe que nos dois casos, por coincidência, a mediana manteve-se,  $M_e=2$ , significando que 50% das famílias possuem menos de 2 filhos ou 50% possuem mais de 2 filhos. Mostra-se assim, que a mediana não é influenciada por valores extremos. Este procedimento pode tornar-se inadequado quando o conjunto de dados for composto por muitos elementos.

### Medidas de dispersão

As medidas de dispersão auxiliam as medidas de tendência central a descrever o conjunto de dados adequadamente e indicam se os dados estão, ou não, próximos uns dos outros.

Desta forma, não há sentido calcular a média de um conjunto onde **não há variação** dos seus elementos. Existe ausência de dispersão e a medida de dispersão é igual a zero. Por outro lado, aumentando-se a dispersão, o valor da medida aumenta e se a variação for muito grande, a média não será uma medida de tendência central representativa.

Faz-se necessário, portanto, ao menos uma medida de tendência central e uma medida de dispersão para descrever um conjunto de dados.

As três medidas de dispersão que serão definidas a seguir, são:

- amplitude total
- variância
- desvio padrão

### Amplitude Total ( $A_t$ )

A amplitude total de um conjunto de dados é a diferença entre o maior e o menor valor observado. A medida de dispersão não levar em consideração os valores intermediários perdendo a informação de como os dados estão distribuídos e/ou concentrados.

$$A_t = x_{\max} - x_{\min}$$

Exemplo: A amplitude total da idade dos alunos que cursam essa disciplina é:  $A_t = 37 - 18 = 19$  anos, isto é, as idades dos alunos diferem em 19 anos.

### Desvio-médio ( $D_m$ )

A diferença entre cada valor observado e a média é denominado desvio.

Ao somar todos os desvios, ou seja, ao somar todas as diferenças de cada valor observado em relação a média, o resultado é igual a zero (propriedade 5 da média). Isto significa que esta medida não mede a variabilidade dos dados. Para resolver este problema, pode-se desconsiderar o sinal da diferença, considerando-as em módulo e a média destas diferenças em módulo é denominada desvio médio:

$$D_m = \frac{\sum_{i=1}^n |x_i - \mu|}{n}$$

### Variância ( $\sigma^2$ ) e Desvio Padrão ( $\sigma$ )

Enquanto não há nada conceitualmente errado em se considerar o desvio médio, esta medida não tem certas propriedades importantes e não é muito utilizada. O mais comum é considerar o quadrado dos desvios em relação à média e então calcular a média. Obtém-se, assim a variância que é definida por:

$$\sigma^2 = \frac{\sum_{i=1}^n (x_i - \mu)^2}{n}$$

Entretanto, ao calcular a variância observa-se que o resultado será dado em unidades quadráticas, o que dificulta a sua interpretação. O problema é resolvido extraindo-se a raiz quadrada da variância, definindo-se, assim, o desvio padrão:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{n}}$$

Exemplo:

Considere três alunos cujas notas em uma disciplina estão apresentadas na tabela abaixo. Observa-se que as médias das notas dos três alunos são iguais, porém, seus desvios em torno da média são diferentes. Isto quer dizer que seus desempenhos são diferentes. O aluno A é constante em seu desempenho, o segundo vai progredindo aos poucos e o terceiro diminui abruptamente seu desempenho. Em outras palavras, apesar dos três alunos terem o mesmo desempenho médio, a variabilidade difere.

Aluno	Notas	Soma	Média $\mu$	$d=x_i-\mu$	$ x_i-\mu $	$(x_i-\mu)^2$	$\sqrt{\sum (x_i-\mu)^2}$
A	8	40	8	0	0	0	$\sqrt{0}=0$
	8			0	0	0	
	8			0	0	0	
	8			0	0	0	
	8			0	0	0	
Total				0	0	0	
B	6	40	8	-2	2	4	$\sqrt{16}=4$
	6			-2	2	4	
	8			0	0	0	
	10			2	2	4	
	10			2	2	4	
Total				0	8	16	
C	10	40	8	2	2	4	$\sqrt{30}=5,48$
	10			2	2	4	
	10			2	2	4	
	5			-3	3	9	
	5			-3	3	9	
Total				0	12	30	

Como demonstrado no exemplo, geralmente, o desvio padrão é maior ou igual ao desvio médio, e isto devido ao fato de que para o cálculo do desvio-padrão, cada desvio em torno da média é elevado ao quadrado, aumentando desproporcionalmente o peso dos valores extremos.

### Exercícios:

Em um treinamento de salto em altura, os atletas realizaram 4 saltos cada um. Veja as marcas obtidas por 3 atletas:

Atleta A	148 cm	170 cm	155 cm	131 cm
Atleta B	145 cm	151 cm	150 cm	152 cm
Atleta C	146 cm	151 cm	143 cm	160 cm

- Qual deles obteve melhor média?
- Qual deles foi o mais regular?

### Referências Bibliográficas

BARBETTA, PEDRO ALBERTO; REIS, MARCELO MENEZES; BORNIA, ANTONIO CESAR. **Estatística para Cursos de Engenharia e Informática**. São Paulo: ed. Atlas, 2004

DANTE, LUIS ROBERTO. **Matemática Contexto e Aplicações, vol 2. 3ª ed.** São Paulo: ed. Ática, 2004

DANTE, LUIS ROBERTO. **Matemática Contexto e Aplicações, vol 3. 3ª ed.** São Paulo: ed. Ática, 2004

Probabilidade e Estatística. Disponível em: <<https://www.youtube.com/watch?v=eFyAyz6Xy6g>> acesso em 08 fev 2018